

# IA/ML – TP555

## APRESENTAÇÃO DO PROJETO – ESTIMAÇÃO DE CANAL BASEDO EM MACHINE LEARNING

Guilherme Pires Piedade - 830

Marco Aurélio de Souza Ferrero - 438

## OVERVIEW

O artigo apresenta um framework baseado em Deep Learning para aplicação em estimação de canal em sistemas OFDM. Neste método, a resposta no tempo e na frequência do canal é modelada como sendo uma imagem 2D, onde são conhecidas apenas as portadoras pilotos. Este modelo com apenas as portadoras pilotos é considerado como sendo uma imagem de baixa resolução, a partir desta imagem o canal é estimado como uma imagem de alta resolução. Para isto, duas abordagens são utilizadas em cascata, utilizar um algoritmo de super-resolução de imagem para melhorar o sinal de entrada, que possui baixa resolução, e em seguida utilizar um método de restauração de imagem, para remover os efeitos causados por ruído. A implementação das duas abordagens citadas é realizada através de dois tipos de Rede Neural Convolutacional (CNN): SRCNN e DnCNN.

## Rede Neural Convolucional - CNN

A CNN usa uma variação de perceptrons multicamada desenvolvidos de modo a demandar o mínimo de pré-processamento possível. Essas redes também são conhecidas como redes neurais artificiais invariantes a deslocamento ou invariantes a espaço.

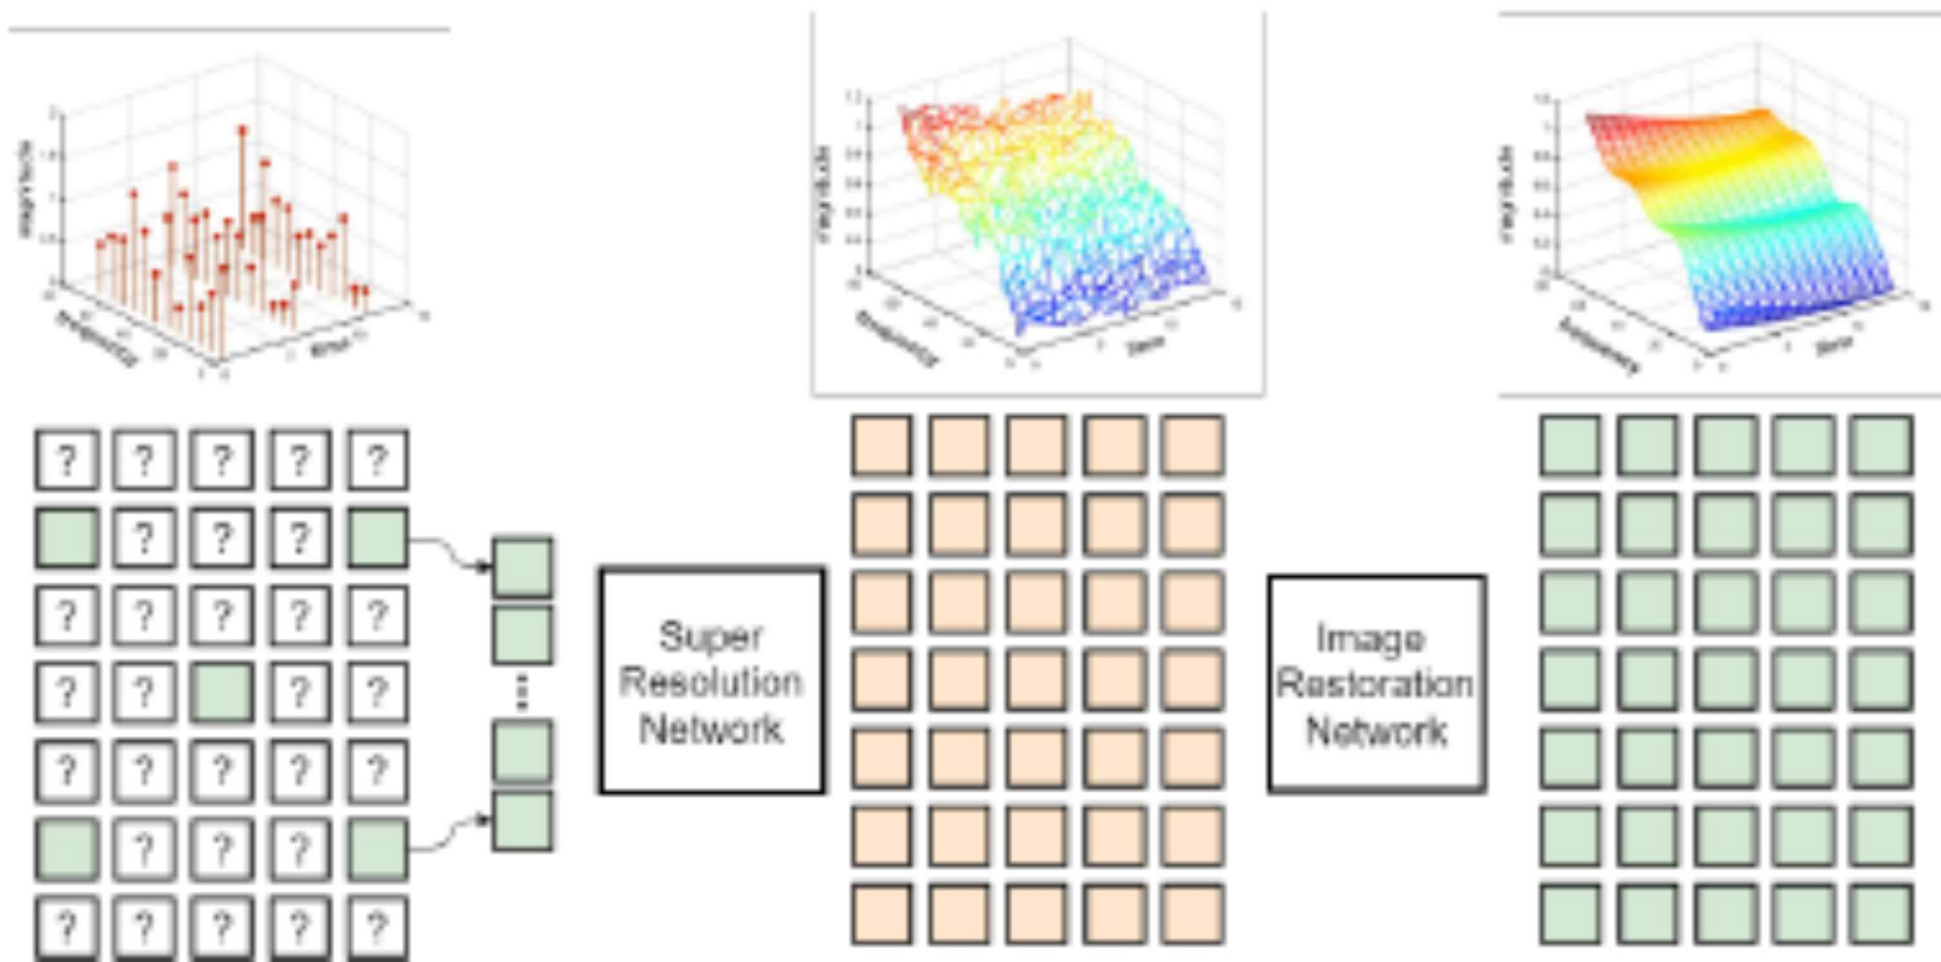
## Super-Resolution Deep Convolutional Neural Network - SRCNN

É um método capaz de aprender a realizar o mapeamento entre imagens de baixa resolução e alta resolução. A rede neural recebe a imagem de baixa resolução como entrada e gera a de alta resolução como saída. Utiliza uma rede convolucional de três camadas formadas por cascatas de matrizes de filtros e retificadores lineares (**ReLU**), comumente utilizados em redes neurais para reconstrução da imagem.

# Denoising Deep Convolutional Neural Networks - DnCNN

O modelo **DnCNN** é capaz de lidar com denoising gaussiano com nível de ruído desconhecido. Com a estratégia de aprendizado residual, o **DnCNN** remove implicitamente a imagem limpa latente nas camadas ocultas. Com esta propriedade, o modelo **DnCNN** é treinado para lidar com várias tarefas gerais de remoção de imagem, como remoção Gaussiana, super-resolução de imagem única e desbloqueio de imagem JPEG. Utiliza uma rede convolucional de 20 camadas formadas também por uma cascata de matrizes de filtros, normalização **BATCH** e **ReLU** para reconstrução da imagem de saída.

# Conjunto de dados proposto baseado em DL para estimação de canal





## TREINAMENTO

A entrada para o algoritmo **ChannelNet** (responsável pelo treinamento das **SR**CNN e **Dn**CNN para estimação de canal) é o vetor de valores das pilotos ( $\mathbf{h}_p^{LS}$  - versão de baixa resolução e ruidosa da imagem) e a saída é a matriz de estimação de canal  $\hat{\mathbf{H}}$ , onde **LS** é método de estimação das pilotos do canal.

A função de perda total da rede é o erro quadrático médio (**MSE**) entre as respostas do canal estimado e o real.

Como forma de simplificação do processo de treinamento é usado um algoritmo de dois estágios de treinamento. Primeiramente são minimizadas as perdas da rede SR e posteriormente, os pesos da rede SR são congelados e os parâmetros de redução do ruído da rede são encontrados.

## TREINAMENTO

Similarmente as técnicas de modelamento baseadas em image-based, os pesos ótimos da rede são dependentes do valor da SNR. Para uma solução completa, seria necessário um novo treinamento da rede para cada valor de SNR mas este processo é muito custoso uma vez que os valores de SNR são contínuos. Os resultados a seguir mostram através de simulações que treinar a rede para alguns poucos valores de SNR pode ainda levar a um bom desempenho do modelo.

## RESULTADOS DAS SIMULAÇÕES

Para a rede treinada é feita uma avaliação do MSE sobre as SNRs onde há de uma comparação dos resultados com os algoritmos de linha de base amplamente utilizados. Neste modelo, é considerado um elemento de antena para o transmissor e um elemento de antena para o receptor (SISO – par de antenas entre TX/RX). Abaixo estão listados alguns parâmetros utilizados neste modelamento:

- Taxa de treinamento = 0,01;
- Tamanho do BATCH = 128;
- Número de iterações = 500 máx.;
- Conjunto de treinamento = 32000 canais;
- Conjunto de teste = 4000 canais;
- Conjunto de validação = 4000 canais;



## RESULTADOS DAS SIMULAÇÕES

Os modelos de canais sem fio veicular (*VehA*) e de propagação em multipath SUI5(*Stanford University Interim - Long delay spread model*) foram utilizados, considerando frequência de portadora de 2,1GHz, BW de 1,6MHz e velocidade do equipamento de usuário (UE) de 50Km/h.

Foi feita a comparação da precisão de estimativa de canal entre o método proposto com algoritmos de última geração MMSE (*Minimum Mean Square Error*) ideal, MMSE estimado e ALMMSE (*Approximated Linear version of Minimum Mean Square Error*) com 48 portadoras pilotos em cada frame. Sendo assim, como métrica de desempenho é considerado o MSE entre o modelo de canal estimado e o modelo de canal real.

## RESULTADOS DAS SIMULAÇÕES

MMSE Ideal – performance ideal, sem erros (conhecimento completo das estatísticas do canal)

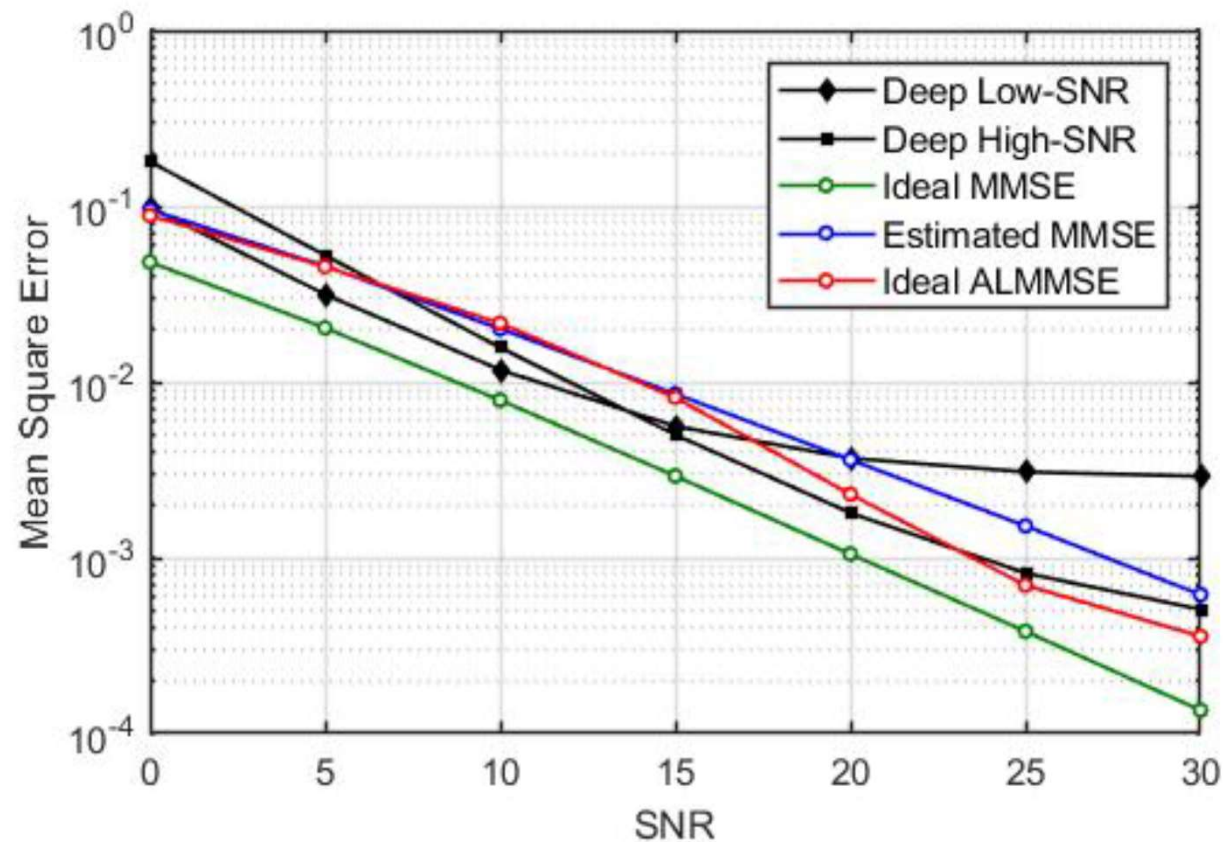
ALMMSE Ideal – aproximação ao MMSE

MMSE Estimado – faz uma estimativa da matriz de correlação com base nos sinais recebidos

Deep Low-SNR – ChannelNET treinada para 12dB

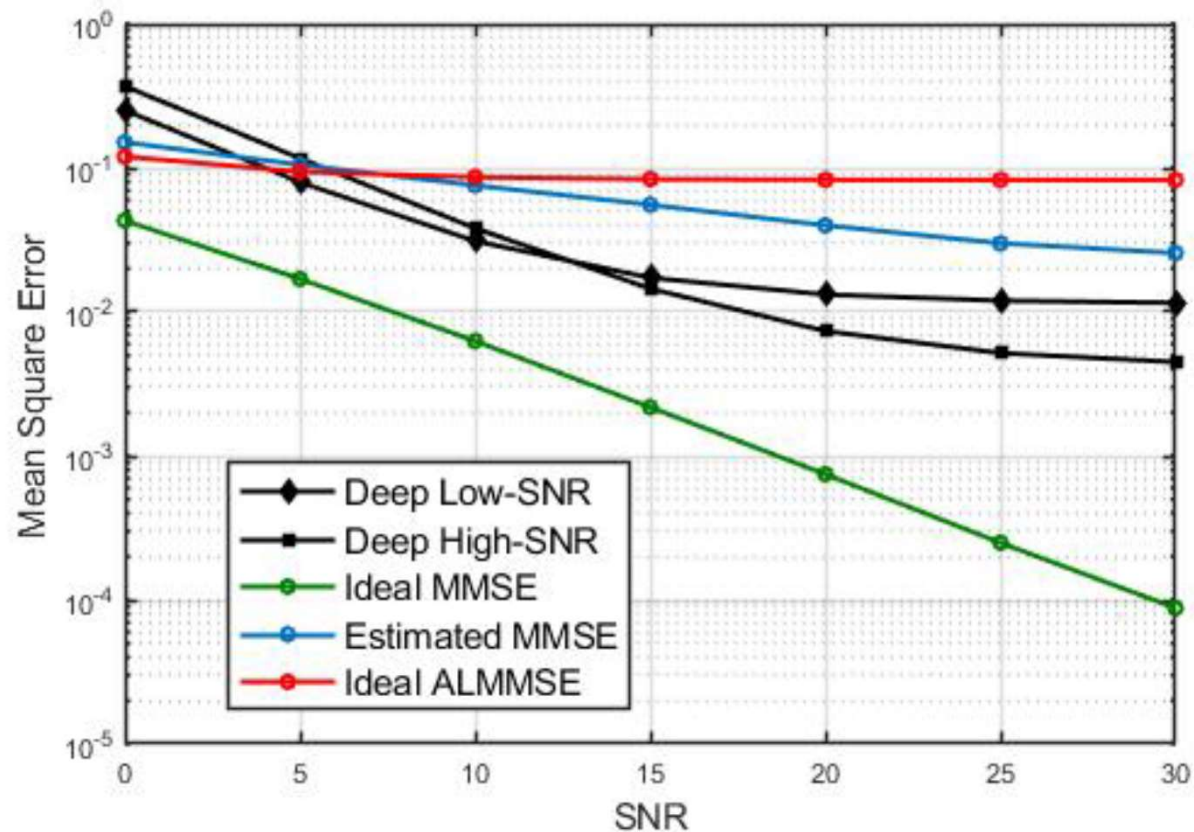
Deep High-SNR - ChannelNET treinada para 22dB

## Estimativa de canal MSE em termos da SNR para o modelo de canal wireless veicular (VehA)



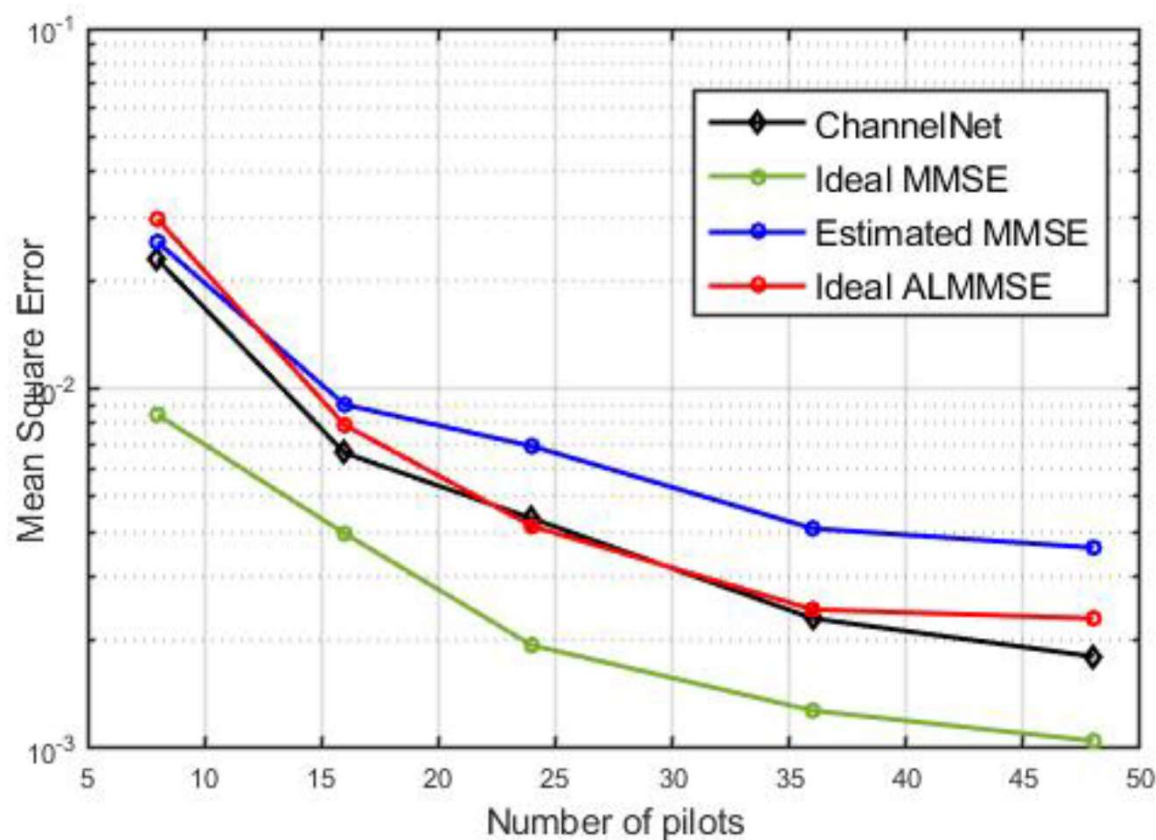
Para valores de SNR abaixo de 12dB, a estimação de canal é feita por Deep Low-SNR e para valores acima, a estimação de canal é feita por Deep High-SNR.

## MSE para estimativa de canal em termos do número de portadoras piloto



Para valores de SNR acima de 5dB, o modelo proposto ainda tem a capacidade de estimação de canal garantindo valores aceitáveis de MSE.

## Conjunto de dados proposto baseado em DL para estimação de canal



Em um canal VehA, o MSE do algoritmo proposto, para uma SNR de 20dB, é comparável ao ideal e supera o estimado com o aumento do número de subportadoras piloto.



## CONCLUSÃO

As contribuições deste artigo podem ser resumidas do seguinte modo:

- Modelamento das respostas no tempo e frequência do canal como uma imagem;
- Considerar a resposta do canal com as portadoras piloto como uma imagem de baixa resolução e a resposta estimada do canal como uma imagem de alta resolução;
- Utilizar Deep-Learning com técnicas de processamento de imagem para estimar o canal.

## SUGESTÕES PARA TRABALHOS FUTUROS

O artigo utiliza duas etapas de treinamento, a primeira para um valor de SNR de 12dB a segunda para SNR de 22dB, e que através dos resultados de simulação fica provado que acima de 22dB este modelo não tem mais eficiência e numa nova CNN deverá ser treinada.

Uma proposta para trabalhos futuros seria investigar novos algoritmos ou novas redes neurais capazes de realizar o treinamento para um número maior de valores de SNR, tendendo ao ideal, com valores contínuos. Com isto, seria possível obter resultados melhores em termos de MSE versus SNR.

## IA/ML – TP555

# PROJETO ESTIMAÇÃO DE CANAL BASEDO EM MACHINE LEARNING

**Obrigado.**

guilhermep@inatel.br  
mferrero@inatel.br